

Named-entity Recognition

Environment types, Running environment, Python version: Colab

AI三 B1228005 胡樂麒

Please describe your data pre-processing workflow

本次作業使用 NCBI Disease 資料集，資料已經事先進行斷詞處理，共分為三個 split：

Train：5,433 筆 Validation：924 筆 Test：941 筆

標籤採用 BIO tagging schema，共三種類別：

O：非疾病名稱

B-Disease：疾病名稱的起始 token

I-Disease：疾病名稱的中間或結尾 token

Tokenization 與 Label 對齊

由於 BERT 系列模型的 tokenizer 會將單一 word 切分為多個 subword（例如 "adenomatous" → "aden", "##om", "##a", "##tou", "##s"），原始資料集以 word 為單位的 label 長度與 tokenized 後的 token 長度不一致，因此需要進行 label 對齊處理。

處理流程如下：

- [CLS] 與 [SEP] 等特殊 token 設為 -100。
- 每個 word 的第一個 subword 繼承該 word 的原始 label
- 後續 subword 同樣繼承相同的 label（選擇2：模型學習所有 subword）

Padding 策略

本次使用動態 padding (Dynamic Padding)，透過 DataCollatorForTokenClassification 在每個 batch 內才進行 padding，補到該 batch 中最長句子的長度，相較靜態 padding 更有效率。

Please describe your model and the hyperparameters

超參數	數值	說明
Model	"bert-base-uncased"	預訓練模型

Train batch size	16	每次訓練時一次丟入16筆資料更新一次權重
Eval batch size	20	評估時一次處理20筆
Epochs	3	整個訓練資料集完整訓練3次
Learning rate	2e-5	控制每次權重更新的幅度，過大容易不收斂，過小則訓練太慢

本次作業使用 bert-base-uncased 預訓練模型。BERT 的核心架構為 Transformer Encoder，能夠同時考慮每個 token 的左右文（雙向），因此對語意的理解能力優於傳統的單向語言模型。而這次使用的 bert-base-uncased 代表輸入文字會統一轉為小寫（uncased），模型架構包含 12 層 Transformer Encoder、768 維 hidden size。

在 NER 任務中，我們使用 AutoModelForTokenClassification 載入 BERT，並在其最後一層加上一個 Token Classification Head（線性分類層），針對每個 token 輸出 3 個類別的分數（logits），再取最大值作為預測結果。進行 fine-tuning。

評估指標使用 seqeval，同時計算 token-level 的 accuracy 以及 entity-level 的 Precision、Recall 與 F1-score。其中 F1-score 的評估標準以完整實體為單位，必須完整識別出整個疾病名稱才算正確，也是本次作業最主要的評估指標。

Please describe your approaches for improving model performance

我主要的改動有兩項

1. 替換為 BioBERT

將基礎模型從通用的 bert-base-uncased 換成生醫領域專用的 BioBERT（dmis-lab/biobert-base-cased-v1.1）。

BioBERT 是在大量 PubMed 生醫論文與 PMC 全文上進行預訓練的 BERT 模型，對疾病名稱、醫學術語等生醫詞彙有更強的理解能力，與 NCBI Disease 資料集的領域較吻合。

2. 增加訓練 Epochs

將訓練輪數從 3 epochs 增加至 5 epochs，讓模型有更多機會學習資料集中的疾病命名模式。

實驗結果比較(eval)

	Epoch	Precision	Recall	F1	Accuracy	loss
"bert-base-uncased"	3	0.8357798165137614	0.8618732261116367	0.8486259897531439	0.9757041360060899	0.07158354746164781
"dmis-lab/biobert-base-cased-v1.1"	5	0.8470684706847068	0.9077328646748682	0.8763520678685048	0.9790281639066843	0.061482589027970914

bert-base-uncased (baseline)	dmis-lab/biobert-base-cased-v1.1
<pre>{'eval_loss': nan, 'eval_precision': 0.8357798165137614, 'eval_recall': 0.8618732261116367, 'eval_f1': 0.8486259897531439, 'eval_accuracy': 0.9757041360060899, 'eval_runtime': 5.5084, 'eval_samples_per_second': 170.831, 'eval_steps_per_second': 8.714, 'epoch': 3.0}</pre> <pre>eval_loader = trainer.get_eval_dataloader() my_eval_loss = compute_eval_loss(model, eval_loader) print("自己算的 eval_loss:", my_eval_loss) 自己算的 eval_loss: 0.07158354746164781</pre>	<pre>... [48/48 00:04] {'eval_loss': nan, 'eval_precision': 0.8470684706847068, 'eval_recall': 0.9077328646748682, 'eval_f1': 0.8763520678685048, 'eval_accuracy': 0.9790281639066843, 'eval_runtime': 5.047, 'eval_samples_per_second': 186.447, 'eval_steps_per_second': 9.511, 'epoch': 5.0}</pre> <pre>eval_loader = trainer.get_eval_dataloader() my_eval_loss = compute_eval_loss(model, eval_loader) print("自己算的 eval_loss:", my_eval_loss) ... 自己算的 eval_loss: 0.061482589027970914</pre>

各指標說明

Precision

模型預測為疾病名稱的結果中，真正是疾病名稱的比例。數值越高代表模型預測時越謹慎、誤報率越低。

Recall

實際存在的疾病名稱中，模型成功找到的比例。數值越高代表模型越不容易漏掉疾病名稱。

F1-score

Precision 與 Recall 的調和平均數，綜合衡量模型效果，是本次作業最主要的評估指標，目標為 $F1 \geq 0.84$ 。

Accuracy

以 token 為單位計算的整體預測正確率。由於資料集中大多數 token 為 0（非疾病），因此 accuracy 數值通常偏高，較不能完整反映模型在疾病辨識上的真實能力，故以 F1 為主要參考指標。

Loss

用來衡量模型預測結果與真實標籤之間的差距，數值越低代表模型預測越接近正確答案。在本實驗中，loss 採用 cross entropy 計算，並以所有有效 token 的平均值作為最終結果。由於序列標註任務中會使用 -100 作為 ignore index（例如 [CLS]、[SEP]），這些位置在理論上不應參與 loss 計算。

然而，在實際使用 Hugging Face Trainer 進行 evaluation 時，eval_loss 有可能因為部分 batch 中有效標籤過少或數值不穩定而出現 NaN。所以我額外用手動計算 loss 的方式，在計算過程中明確過濾掉 -100 的位置，並只針對有效標籤進行 cross entropy 計算，同時在遇到無有效標籤的 batch 時予以跳過。避免數值異常。

結果分析

BioBERT 在所有指標上均優於 BERT baseline：

Recall 提升最為明顯（+4.58%）：BioBERT 對生醫術語的理解更深，能識別出更多真正的疾病名稱，大幅降低漏報率。

Precision 小幅提升（+1.13%）：模型預測更為準確，誤報情況略有減少。

F1 整體提升約 2.78%（0.8486 → 0.8764）。

Loss 也由 0.0716 降至 0.0615，代表 BioBERT 的預測結果與真實標籤之間的差距更小，模型在 validation/test 資料上的收斂效果較佳。

What do you believe is the primary factor affecting model performance in your approach?

我覺得影響模型表現最主要的原因是，預訓練模型與該資料集的匹配程度。NER 任務的核心挑戰在於模型必須理解詞彙在特定領域中的語義。以 NCBI Disease 資料集來說，疾病名稱往往由複雜的醫學術語組成，這些詞彙在一般英文語料中極少出現，bert-base-uncased 對這類詞彙的語義表示較為薄弱。相較之下，BioBERT 在大量生醫論文上進行額外預訓練，對這類術語有更豐富的語義表示，因此在相同的 fine-tuning 框架、相似的超參數設定下（當然增加 epoch 也會依定程度影響模型表現），BioBERT 能取得明顯更好的結果。可以看到輸出結果 Recall 提升（+4.58%）。Recall 代表模型找到所有真實疾病名稱的能力，BioBERT 在這方面的進步遠大於 Precision

的提升，說明模型對生醫詞彙的辨識能力確實更強，能識別出 bert-base-uncased 容易忽略的專業疾病術語。因此，在特定領域的 NLP 任務中，相比於調整超參數，我認為選擇與任務領域匹配的預訓練模型是提升效能最直接有效的方法。

Anything that can strengthen your report.

我使用Tensorboard來畫圖。

圖一為 training loss 的變化情形。從圖中可以看到，隨著訓練 step 增加，兩次實驗的 training loss 都呈現明顯下降趨勢。第一次實驗在 step 1000 時，loss 約為 0.0323；第二次實驗在 step 1500 時，loss 進一步下降到約 0.0096。這代表模型在訓練過程中確實有逐漸學到資料中的特徵，並且模型的預測結果與真實標籤之間的誤差越來越小。整體曲線沒有出現明顯震盪或突然上升的情況，表示訓練過程相對穩定，learning rate 並沒有過大到造成模型發散。尤其第二次實驗的 loss 下降幅度更明顯，表示該次設定下模型收斂效果較佳，能更有效地降低訓練誤差。

圖二為 evaluation F1-score 的變化情形。F1-score 是衡量模型在 NER 任務中整體辨識能力的重要指標，會同時考慮 precision 與 recall。從圖中可以看到，兩次實驗的 F1-score 都隨著訓練 step 增加而上升，代表模型在驗證資料上的表現逐漸改善。第一次實驗最後約達到 0.8486，第二次實驗則提升到約 0.8764。這表示模型能夠將學到的特徵應用到未見過的資料上，具有一定的泛化能力。由於 evaluation F1-score 沒有隨著訓練進行而下降，因此目前沒有明顯 overfitting 的現象。第二次實驗的 F1-score 較高，代表其模型設定或訓練效果比第一次更好。



